

Trabajo Práctico 2 - Vision por Computadora - Redes Neuronales Convolucionales

Gonzalo Angaut, Angel Valentino Indorato, Fredy Alexander Restrepo Blandon

En el presente trabajo se construyó una red neuronal convolucional para hacer clasificación sobre el conjunto de Fashion-MNIST. Al evaluar su funcionamiento, logramos comparar su poder de predicción con el de una red neuronal artificial (ANN) estándar del trabajo previo.

I. INTRODUCCIÓN

Las redes neuronales convolucionales (CNN, por sus siglas en inglés) son un tipo de red neuronal artificial, donde las neuronas artificiales corresponden a campos receptivos de una manera muy similar a las neuronas en la corteza visual primaria (V1) de un cerebro biológico. A diferencia de las redes neuronales estándar, las CNN contienen capas de filtros y están diseñadas para extraer características espaciales y jerárquicas.

Las redes convolucionales aparecen en la década de 1980 y uno de las primeras arquitecturas con gran impacto fue la LeNet, que puede verse en la figura 1. Esta se usaba principalmente para tareas de reconocimiento de caracteres, como leer códigos postales, dígitos, etc. Desde entonces, se han propuesto muchas mejoras a esta arquitectura pero todas siguen los fundamentos de la LeNet.




Figura 1: Arquitectura de la LeNet.

Hay cuatro operaciones principales que contiene cualquier red convolucional:

- Capa de convolución: Su propósito principal es extraer características de la imagen de entrada. La convolución preserva la relación espacial entre píxeles al aprender las características de la imagen utilizando pequeñas regiones de datos de la imagen de entrada.
- Función de activación / No linealidad: Luego de cada operación de convolución, se utiliza una función de activación llamada *ReLU* que significa unidad lineal rectificadora e introduce no linealidades.
- Pooling o Submuestreo: Reduce la dimensionalidad de cada feature map, reteniendo la información más importante.
- Clasificador (capas totalmente conectadas): La última capa es una MLP tradicional que nos da como salida el clasificador.

En este trabajo, creamos una red convolucional simple con el fin de utilizarla con el conjunto de datos de

Fashion-MNIST. Del trabajo realizado previamente tenemos la precisión para una red neuronal estándar, por lo que veremos una comparación entre ambos funcionamientos.

II. PROCEDIMIENTO

Comenzamos trabajando con la base de datos de Fashion-MNIST. Esta contiene 70000 imágenes en escala de grises de prendas de vestir separadas en 10 categorías distintas. Las imágenes son de 28x28 píxeles.

Luego, construimos una red convolucional para clasificar este conjunto de datos. Por el tamaño de las imágenes, la red debe tomar como entrada tensores con forma (28, 28, 1). La arquitectura de la red es la siguiente:

- Una capa convolucional que toma como entrada tensores de la forma (28, 28, 1) y utiliza 32 filtros de 3x3 con función de activación *ReLU*.
- Un maxpooling (pooling donde toma el valor máximo en cada ventana) con ventanas de 2x2.
- Otra capa convolucional pero de 64 filtros 3x3 con función de activación *ReLU*.
- Otro maxpooling con ventanas 2x2.
- Finalmente otra capa convolucional con 64 filtros 3x3 y función de activación *ReLU*.

Para completar el modelo utilizamos el tensor de salida para alimentar una ANN que nos permita hacer la clasificación. Para eso, comenzamos con un *flatten* para tener un arreglo de una sola dimensión y después usamos una capa oculta de 64 neuronas con función de activación *ReLU*, seguida de la capa de salida con 10 neuronas (outputs) con función de activación *softmax*. La arquitectura total de la red puede verse en la figura 2.

Al compilar el modelo, se utilizó el optimizador *Adam*, la función de pérdida *sparse categorical crossentropy* y la métrica de *accuracy*. Luego, se entrenó la red utilizando *backpropagation* durante 10 épocas.

III. RESULTADOS

Ya definido y entrenado el modelo, lo evaluamos utilizando el conjunto de testeo. En la imagen 3 pueden verse gráficos del *accuracy* en función de las épocas de entrenamiento, tanto para el conjunto de entrenamiento (en




Figura 2: Arquitectura de la red convolucional.

azul) como para el de testeo (en naranja). Puede observarse que cuanto más entrenamiento, la precisión mejora en el conjunto de entrenamiento, mientras que en el conjunto de testeo parece estancarse. Por lo tanto, realizar más épocas puede llevar al sistema a un *overfitting*.

El *accuracy* medido, una vez finalizado el entrenamiento, para el conjunto de testeo es del 90 %, ligeramente superior a la del ANN sin convolución que había resultado del 87 %.




Figura 3: *Accuracy* para el conjunto de entrenamiento y de testeo en función de las épocas.

IV. DISCUSIÓN

En el presente trabajo estudiamos el funcionamiento de una red neuronal convolucional (CNN) con el objetivo de clasificar prendas del conjunto Fashion-MNIST.

La red implementada fue una arquitectura sencilla que consta de tres capas de convolución: las dos primeras seguidas de una capa de *max pooling* y la última seguida de una capa *flatten*, para luego conectarse a una capa completamente conectada (*fully connected*) encargada de realizar la clasificación.

A pesar de su simplicidad, esta arquitectura permitió mejorar ligeramente la precisión obtenida previamente con una red sin convoluciones, lo que evidencia el poder de las CNN para el reconocimiento de patrones espaciales. Como posible mejora, podría incorporarse *dropout* o agregar capas adicionales para optimizar el desempeño del modelo.